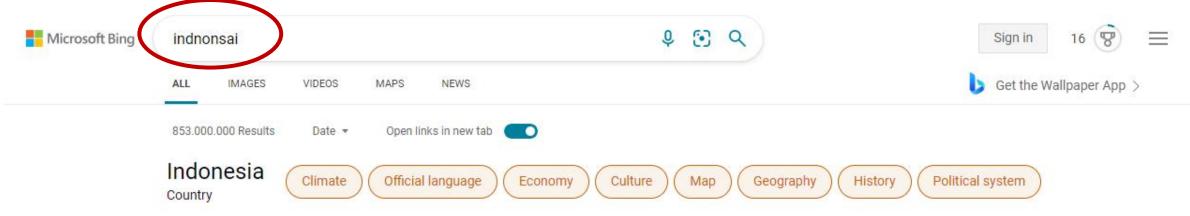
# Spleling Corecssion

Alfan Farizki Wicaksono Fakultas Ilmu Komputer, Universitas Indonesia



Mount Bromo, Surabaya Zoo,

Heroes Monument



National Monument, Istiglal

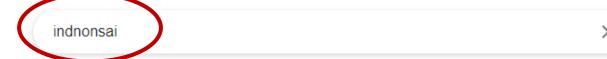
Mosque, Taman Mini Indon...

Mount Agung, Tanah Lot,

Mount Batur













Indonesia



Q Semua

Maps

Berita

Video

Gambar

: Lainnya

Alat

SafeSearch a

Sekitar 5.700.000.000 hasil (0,77 detik)

#### Menampilkan hasil untuk indonesia

Atau telusuri indnonsai

https://id.wikipedia.org > wiki > Indonesia 🔻

#### Wikipedia bahasa Indonesia, ensiklopedia bebas

**Indonesia** merupakan negara terluas ke-14 sekaligus negara kepulauan terbesar di dunia dengan luas wilayah sebesar 1.904.569 km², serta negara dengan pulau ...

Bahasa daerah: Lebih dari 700 bahasa

Agama (2018): 86,70% Islam; 10,72% ...

Kota terbesar: Jakarta; 6°10'S 106°49'E / ... Format tanggal: DD/MM/YYYY

Indonesia Raya · Bahasa Indonesia · Bangsa Indonesia · Presiden Indonesia



#### Indonesia

Negara di Asia

Indonesia, dengan nama resmi Republik Indonesia, atau lengkapnya Negara Kesatuan Republik Indonesia, adalah sebuah negara kepulauan di Asia Tenggara yang dilintasi garis khatulistiwa dan berada di antara ... Wikipedia

Ibu kota: Jakarta

Luas: 1,905 juta km²

Presiden: Joko Widodo

Populasi: 273,5 juta (2020) Bank Dunia

#### Berita utama

✓ ANTARAKALSEL

Anggota DPRD Kalsel Karlie: Pancasila aset negara Indonesia

2 jam lalu



✓ ANTARANEWS

.com

Borussia Dortmund akan jalani tur ke Indonesia

2 jam lalu



### Tolerant Retrieval

Bagaimana membuat search engine yang "mempunyai toleransi" terhadap kesalahan syntax pada query?

Rates of Spelling Errors -> 26% for Web queries (Wang et al., 2003)

# Types of Spelling Errors

- Non-word Errors
  - graffe -> giraffe

Kata-kata yang tidak ditemukan di kamus baku. Biasanya context insensitive

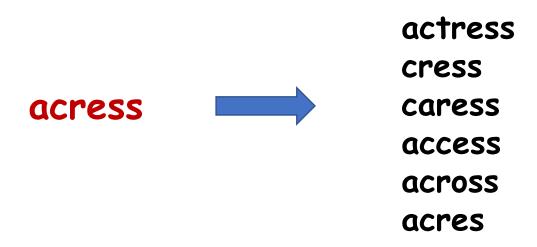
- Real-word Errors
  - Typographical errors
    - three -> there
  - Cognitive errors
    - piece -> peace
    - too -> two
    - your -> you're

Biasanya context sensitive

## Non-Word Errors: Bagaimana?

acress

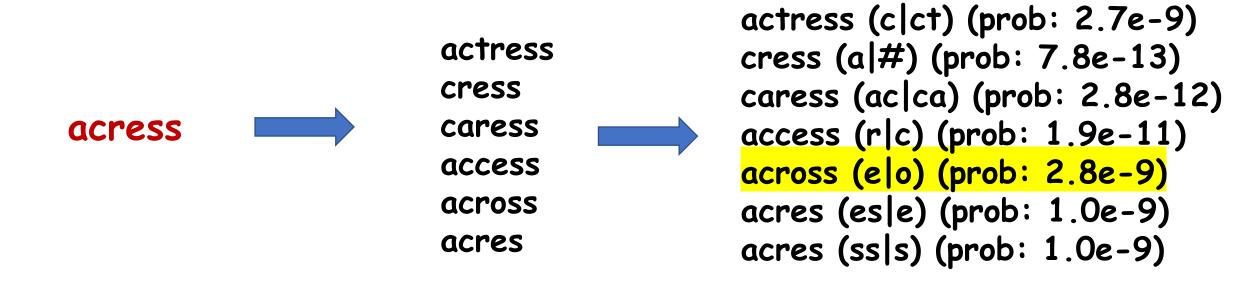
### Non-Word Errors: Bagaimana?



#### Candidate Generation

- Words with similar spelling
- · Words with similar pronounciation

### Non-Word Errors: Bagaimana?



Choose the best candidate!

Scoring with a probability model, such as Noisy Channel Model.

### Candidate Testing: Minimal Edit Distance

- Kita perlu mekanisme atau metrik untuk mengukur "kedekatan ejaan" antara dua buah string.
- Salah satu realisasi "kedekatan ejaan" -> berapa banyak langkah minimal yang perlu saya lakukan untuk edit string X ke string Y.
- Metrik tersebut perlu efisien untuk dihitung.

## 4 Kemungkinan Edit Actions

Insertions

car -> ca<mark>r</mark>t

Deletions

traine -> train

Substitutions

cart -> <mark>d</mark>art

Transpositions

act -> cat

### Words within 1 of acress

	Words within 1 of acress										
Error	Candidate Correction	Correct Letter	Error Letter	Туре							
acress	actress	t	-	deletion							
acress	cress	-	a	insertion							
acress	caress	ca	ac	transposition							
acress	access	С	r	substitution							
acress	across	0	е	substitution							
acress	acres	-	s	insertion 27							

Gambar diambil tanpa malu dari slide Chris Manning & Pandu Nayak, IR & Web Search, Stanford U.

### a cash -> an act

#Edit actions = 5

a cash -> an cash -> an aash -> an acsh -> an acth -> an act

insertion

substitution substitution substitution

deletion

• a cash -> an cash -> an acsh -> an ach -> ac ac -> an act

insertion

transposition

deletion

deletion

insertion

#Edit actions = 5

a cash -> an cash -> an acsh -> an acth -> an act

#Edit actions = 4

insertion

transposition substitution

deletion

Dan yang lainnya. Ada banyak kemungkinan ...

### Damerau-Levenshtein Edit Distance

Given two strings x and y, DL Edit Distance between them is the shortest or cheapest possible sequence of edit actions from x to y.

### a cash -> an act

Menurut Anda, paling sedikit, berapa banyak edit actions?

Menurut Damerau, 80% spelling error di Information Retrieval system adalah pada edit distance 1.

```
Distance("xxazzzb", "xxbuua") =
```

```
Distance("xxazzz", "xxbuu") + 1
             Distance("xxazzzb", "xxbuu") + 1
minimum
             Distance("xxazzz", "xxbuua") + 1
             Distance("xx", "xx") + 1 + 3 + 2
```

Distance("xxazzzb", "xxbuua") =

Cost untuk
Substitution b
dengan a

Distance("xxazzz", "xxbuu") + 1 Distance("xxazzzb", "xxbuu") + 1 minimum Distance("xxazzz", "xxbuua") + 1 Distance("xx'', "xx'') + 1 + 3 + 2

```
Distance("xxazzzb", "xxbuua") =
                                              Cost untuk
                  Distance ("xxazzz", " Insertion a ke string pertama
                   Distance("xxazzzb", "xxbuu") + 1
   minimun
                   Distance("xxazzz", "xxbuua") + 1
                   Distance("xx'', "xx'') + 1 + 3 + 2
```

Distance("xxazzzb", "xxbuua") =

```
Distance ("xxazzz", "xxbuu") + 1

Cost untuk

Deletion b pada

string pertama
minimum
                  Distance("xxazzz", "xxbuua") + 1
                   Distance("xx'', "xx'') + 1 + 3 + 2
```

Distance("xxazzzb", "xxbuua")

Cost untuk menyisipkan 3 Distance ("xxa: karakter di antara a dan b di string pertama

minimum

Cost untuk transposisi a dan b di string pertama

Distance("xxazzz", "xxbuuh")

Distance("xx'', "xx'') + 1 + 3

Banyaknya karakter antara b dan a di string kedua

### Assumption for Transposition Cost

#### Hanya ada dua cara:

- Transposisi huruf dan sisipkan karakter diantara mereka
- Hapus semua karakter diantara dua karakter yang mau ditransposisi; baru lakukan transposisi

Distance("xxxab", "xxxcb") =

Cost untuk
Substitution b
dengan b

Distance("xxxa", "xxxc") + 0

Distance("xxxab", "xxxc") + 1

Distance("xxxa", "xxxcb") + 1

Distance(-, -) + 1 + 4 + 4

### minimum

#### Wagner-Fischer Table

			A	N		A	C	T
	12	12	12	12	12	12	12	12
	12	0	1	2	3	4	5	6
A	12	1	0	1	2	3	4	5
	12	2	1	1	1	2	3	4
C	12	3	2	2	2	2	2	3
A	12	4	3	3	3	2	2	3
5	12	5	4	4	4	3	3	3
Н	12	6	5	5	5	4	4	4

12 adalah Panjang(AN ACT) + Panjang (A CASH) = 6 + 6 = 12

Apa maksudnya?

Jawaban: edit distance

			A	N		A	C	T
	12	12	12	12	12	12	12	12
	12	0	1	2	3	4	5	6
A	12	1	0	1	2	3	4	5 (
	12	2	1	1	1	2	3 (	?
C	12	3						
A	12	4						
5	12	5						
Н	12	6						

```
Dist("A", "AN AC") = 3
Dist("A", "AN AC") = 4
Dist("A", "AN ACT") = 5
```

Berapakah Dist("A ", "AN ACT")?

Siapa yang paling minimal total cost-nya diantara 4 jenis aksi?

Misal, baru terisi Sebagian, dan yang akan diisi berikutnya adalah baris 2 kolom 6

#### Wagner-Fischer Table

			A	N		A	C	T	
	12	12	12	12	12	12	12	12	Jika substitution:
	12	0	1	2	3	4	5	6	= Dist("A", "AN AC")
A	12	1	0	1	2	3	4	5	= 4 + 1 = 5
	12	2	1	1	1	2/	3 (	?	
C	12	3							
A	12	4							
5	12	5						•	A", "AN AC") setelah
Н	12	6		— mei	milin c	psi su	<mark>ıbstiti</mark>	ution	

#### Wagner-Fischer Table

			A	N		A	C	T	
	12	12	12	12	12	12	12	12	Jika insertion:
	12	0	1	2	3	4	5	6	= Dist("A ", "AN A
A	12	1	0	1	2	3	4	5	= 3 + 1 = 4
	12	2	1	1	1	2	3 (	?	
C	12	3							
A	12	4							
5	12	5		_		total	cost E	dit("	d ", " AN AC") setelah memilih op
Н	12	6		— inso	ert   				

			A	N		A	C	T
	12	12	12	12	12	12	12	12
	12	0	1	2	3	4	5	6
A	12	1	0	1	2	3	4	5
	12	2	1	1	1	2	3 (	?
C	12	3						
A	12	4						
5	12	5						
Н	12	6						

Jika deletion:

5 adalah total cost Edit("A", "AN ACT") setelah memilih opsi deletion

#### Wagner-Fischer Table

			A	N		A	C	T	
	12	12	12	12	12	12	12	12	J
	12	0	1	2	3	4	5	6	=
A	12	1	0	1	2	3	4	5	=
	12	2	1	1	1	2	3 (	?	
C	12	3							
A	12	4							
S	12	5			h tota memil			•	•
Н	12	6							

#### Jika transposition:

= Dist(-, "AN") + 1 + 1 + 2  
= 
$$12 + 1 + (2-0-1) + (6-3-1) = 15$$

			A	N		A	C	T
	12	12	12	12	12	12	12	12
	12	0	1	2	3	4	5	6
A	12	1	0	1	2	3	4	5
	12	2	1	1	1	2	3 (	4
C	12	3						
A	12	4						
5	12	5						
Н	12	6						

Cost insertion yang totalnya menjadi paling kecil

#### Wagner-Fischer Table

			A	N		A	C	T
	12	12	12	12	12	12	12	12
	12	0	1	2	3	4	5	6
A	12	1	0	1	2	3	4	5
	12	2	1	1	1	2	3	4
C	12	3	2	2	2	2	2	3
A	12	4	3	3	3	2	?	
S	12	5						
Н	12	6						

Misal, baru terisi Sebagian, dan yang akan diisi berikutnya adalah baris 4 kolom 5

			A	N		A	C	T
	12	12	12	12	12	12	12	12
	12	0	1	2	3	4	5	6
A	12	1	0	1	2	3	4	5
	12	2	1	1	1	2	3	4
C	12	3	2	2	2	2	2	3
A	12	4	3	3	3	2	?	
5	12	5						
Н	12	6						

$$2 + 1 = 3$$

Jika insertion:

$$2 + 1 = 3$$

Jika deletion:

$$2 + 1 = 3$$

			A	N		A	C	T
	12	12	12	12	12	12	12	12
	12	0	1	2	3	4	5	6
A	12	1	0	1	2	3	4	5
	12	2	1	1	1	2	3	4
C	12	3	2	2	2	2	2	3
A	12	4	3	3	3	2	?	
5	12	5						
Н	12	6						

$$2 + 1 = 3$$

Jika insertion:

$$2 + 1 = 3$$

Jika deletion:

$$2 + 1 = 3$$

Jika transposisi:

$$1 + 1 + (4-3-1) + (5-4-1) = 2$$

			A	N		A	C	T
	12	12	12	12	12	12	12	12
	12	0	1	2	3	4	5	6
A	12	1	0	1	2	3	4	5
	12	2	1	1	1	2	3	4
C	12	3	2	2	2	2	2	3
A	12	4	3	3	3	2	2	
5	12	5						
Н	12	6						

$$2 + 1 = 3$$

Jika insertion:

$$2 + 1 = 3$$

Jika deletion:

$$2 + 1 = 3$$

Cost paling kecil

Jika transposisi:

$$1 + 1 + (4-3-1) + (5-4-1) = 2$$

#### Wagner-Fischer Table

			A	N		A	C	T
	12	12	12	12	12	12	12	12
	12	0	1	2	3	4	5	6
A	12	1	0	1	2	3	4	5
	12	2	1	1	?			
C	12	3						
A	12	4						
5	12	5						
Н	12	6						

Misal, baru terisi Sebagian, dan yang akan diisi berikutnya adalah baris 2 kolom 3

			A	N		A	C	T
	12	12	12	12	12	12	12	12
	12	0	1	2	3	4	5	6
A	12	1	0	1	2	3	4	5
	12	2	1	1	?			
C	12	3						
A	12	4						
5	12	5						
Н	12	6						

$$1 + 0 = 1$$

Jika insertion:

$$1 + 1 = 2$$

Mengapa 0? Bukan 1?

Jika deletion:

$$2 + 1 = 3$$

Jika transposisi:

$$12 + 1 + (2-0-1) + (3-0-1) = 16$$

			A	N		A	C	T
	12	12	12	12	12	12	12	12
	12	0	1	2	3	4	5	6
A	12	1	0	1	2	3	4	5
	12	2	1	1	1			
C	12	3						
A	12	4						
5	12	5						
Н	12	6						

$$1 + 0 = 1$$

Jika insertion:

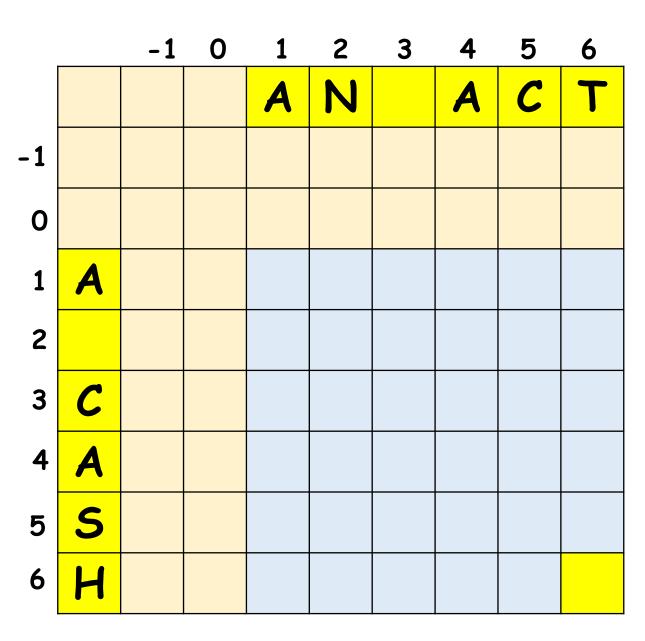
$$1 + 1 = 2$$

Jika deletion:

$$2 + 1 = 3$$

Jika transposisi:

$$12 + 1 + (2-0-1) + (3-0-1) = 16$$



#### Solusi yang terinspirasi Lowrance-Wagner Algorithm untuk String-to-String Correction

ı		-1	0	1	2	3	4	5	6	
		•		A	N		A	C	T	DL-dist(a[1 len(a)], b[1 len(b)]):
-1		12	12	12	12	12	12	12	12	<pre>// wagner-fischer matrix // ukuran: (len(a) + 2)</pre>
0		12	0	1	2	3	4	5	6	<pre>init dist = array[-1 maxdist = len(a) + len(b</pre>
1	A	12	1							dist[-1, -1] = maxdist
2		12	2							<pre>for i = 0 to len(a):     dist[i, -1] = maxdist</pre>
3	C	12	3							dist[i, 0] = i
4	A	12	4							<pre>for j = 0 to len(b):     dist[-1, j] = maxdist</pre>
5	5	12	5							dist[0, j] = j
6	Н	12	6							Continued

```
x (len(b) + 2)
len(a), -1 .. len(b)]
b)
```

#### Solusi yang terinspirasi Lowrance-Wagner Algorithm untuk String-to-String Correction

ı		-1	0	1	2	3	4	5	6
				A	2		A	C	T
-1		12	12	12	12	12	12	12	12
0		12	0	1	2	3	4	5	6
1	A	12	1	0	1	2	3	4	5
2		12	2	1	1	1	2	3	4
3	C	12	3	2	2	2	2	2	3
4	A	12	4	3	3	3	2	2	3
5	S	12	5	4	4	4	3	3	3
6	Н	12	6	5	5	5	4	4	4
ļ									

```
init lastrow = {} // a map or dictionary
for i = 1 to len(a):
  lastcol = 0
 for j = 1 to len(b):
   lmr = lastrow[b[j]] // return 0 if not found
   lmc = lastcol
    if a[i] == b[j]:
     cost = 0
     lastcol = j
   else:
     cost = 1
   dist[i, j]
       = min( dist[i-1, j-1] + cost, //substitution
             dist[i, j-1] + 1, //insert
             dist[i-1, j ] + 1, //delete
             dist[lmr - 1, lmc - 1] + 1
             + (i - lmr - 1) //transposition
             + (i - lmc - 1))
  lastrow[a[i]] = i
return dist[len(a), len(b)]
```

	Menyimpan informasi posisi di string a terakhir (last row) yang match dengan karakter di string b yang sedang														
	diinspeksi														
1		12	12	12	12	12	12	12	12						
0		12	0	1	2	3	4	5	6						
1	A	12	1	0	Imr: last match row										
2		12	2	1	Im	c: last	matc	h colu	ımn						
3	C	12	3	2	2	2	2	2	3						
4	A	12	4	3	3	3	2	2	3						
5	S	12	5	4	4	4	3	3	3						
6	Н	12	6	5	5	5	4	4	4						

```
init lastrow = {} // a map or dictionary
 for i = 1 to len(a):
   lastcol = 0
   for j = 1 to len(b):
     lmr = lastrow[b[j]] // return 0 if not found
     lmc = lastcol
     if a[i] == b[j]:
      cost = 0
       lastcol = j
     else:
       cost = 1
     dist[i, j]
        = min( dist[i-1, j-1] + cost, //substitution
               dist[i, j-1] + 1, //insert
               dist[i-1, j ] + 1, //delete
               dist[lmr - 1, lmc - 1] + 1
               + (i - lmr - 1) //transposition
               + (j - lmc - 1))
   lastrow[a[i]] = i
 return dist[len(a), len(b)]
```

#### Latihan

 Buat tabel Wagner-Fischer untuk DL-distance("BKAOC", "KACO")

#### How to generate candidates?

- Periksa ke setiap kata di kamus baku, lalu pilih kata-kata dengan DL edit distance < k. Misal k = 2.</li>
- Ada solusi yang lebih cepat dengan Levenshtein automaton, yaitu O(N) dengan N adalah panjang string input.
  - <a href="http://blog.notdot.net/2010/07/Damn-Cool-Algorithms-Levenshtein-Automata">http://blog.notdot.net/2010/07/Damn-Cool-Algorithms-Levenshtein-Automata</a>

Jika ada yang mau coba eksplorasi dan implementasikan kode pada blog di atas, akan diberikan nilai 400 untuk week 4.

# Finding The Best Candidate

## Noisy Channel Model = Bayes' Rule

Yang diprediksi merupakan kata yang benar

$$\widehat{w} = \operatorname*{argmax} P(w|x)$$

$$w \in V$$

x: observation, kata yang salah eja

$$= \underset{w \in V}{\operatorname{argmax}} \frac{P(x|w)P(w)}{P(x)}$$

$$\propto \underset{w \in V}{\operatorname{argmax}} P(x|w)P(w)$$

#### Sebuah "Likelihood":

Seberapa mungkin kata w "rusak" menjadi kata x karena melawati noisy channel?

Noisy Channel Model

Prior Probability

# Prior Probability P(w)?

- Merupakan "language model", atau lebih tepatnya "word model"
- Seberapa besar kemungkinan kita observasi w di corpus yang sangat besar.
- · Dengan Maximum Likelihood Estimation (MLE), dapat diestimasi dengan

Estimasi dari P(w)  $\widehat{P}(w) = \frac{C(w)}{T}$ 

Berapa kali kata w muncul di koleksi yang besar

Banyaknya token di sebuah koleksi yang besar

## Prior Probability P(w)?

#### Koleksi

- D1: hujan sejuk pagi hari
- D2: udara sejuk dan pagi penuh semangat
- D3: tiada hujan tanpa kebaikan

$$\hat{P}(hujan) = \cdots$$

### Prior Probability P(w)

404.253.213 kata pada Corpus of Contemporary English (COCA)

word	word frequency C(w)	Estimated P(w)
actress	9.231	.0000230573
cress	220	.000005442
caress	686	.0000016969
access	37.038	.0000916207
across	120.844	.0002989314
acres	12.847	.0000318463

## Noisy Channel Model

Salah satunya adalah dengan Edit Probability (Kernighan, Church & Gale, 1990)

Edit Probability - koreksi hanya 1 step dari 4 kemungkinan: insertion, deletion, substitution, transposition

$$P(x|w) = P(x_1, x_2, x_3, ..., x_n|w_1, w_2, w_3, ..., w_n)$$

Untaian karakter dari kata salah eja x

Untaian karakter dari kata yang benar

Aksi yang

menyebabkan

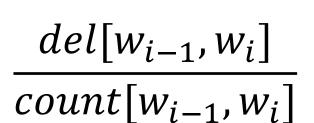
## Single Step Correction

salah eja. **Transformation** Correction Typo deletion actress acress insertion # acress cress reversal ac ca 0 acress caress substitution acress access substitution acress across 0 # insertion 4 acress acres # insertion acress acres

<sup>@</sup> and # represents nulls in the typo and correction, respectively.

### Noisy Channel Model

Aksi yang menyebabkan salah eja.



Jika deletion

$$\frac{ins[w_{i-1}, x_i]}{count[w_{i-1}]}$$

Jika insertion

$$\frac{sub[w_i, x_i]}{count[w_i]}$$

Jika substitution

$$\frac{trans[w_i, w_{i+1}]}{count[w_i, w_{i+1}]}$$

Jika transposition

del[x,y]: berapa kali karakter berurutan xy (pada kata benar) diketik sebagai x pada training dataset.

ins[x,y]: berapa kali karakter x diketik sebagai xy

sub[x,y]: berapa kali karakter x diketik sebagai y

trans[x,y]: berapa kali karakter xy diketik sebagai yx

count[x,y]: berapa kali karakter berurutan xy muncul di training dataset

count[x]: berapa kali karakter x muncul di training dataset

 $\hat{P}(x|w) =$ 

#### Kernighan's Confusion Matrix

#### Substitution of X (incorrect) for Y (correct)

X												Y	(co	rrect)	)			•		•						
	a	b	С	d	e	f	g	h	_ i	j	k	1	m	n	0	p_	q	r	S	t	u	V	w	х	у	Z
a	0	0	7	1	342	0	0	2	118	0	1	0	0	3	76	0	0	1	35	9	9	0	1	0	5	0
b	0	0	9	9	2	2	3	1	0	0	0	5	11	5	0	10	0	0	2	1	0	0	8	0	0	0
c	6	5	0	16	0	9	5	0	0	0	1	0	7	9	1	10	2	5	39	40	1	3	7	1	1	0
d	1	10	13	0	12	0	5	5	0	0	2	3	7	3	0	1	0	43	30	22	0	0	4	0	2	0
е	388	0	3	11	0	2	2	0	89	0	0	3	0	5	93	0	0	14	12	6	15	0	1	0	18	0
f	0	15	0	3	1	0	5	2	0	0	0	3	4	1	0	0	0	6	4	12	0	0	2	0	0	0
g	4	1	11	11	9	2	0	0	0	1	1	3	0	0	2	1	3	5	13	21	0	0	1	0	3	0
h	1	8	0	3	0	0	0	0	0	0	2	0	12	14	2	3	0	3	1	11	0	0	2	0	0	0
i	103	0	0	0	146	0	1	0	0	0	0	6	0	0	49	0	0	0	2	1	47	0	2	1	15	0
j	0	1	1	9	0	0	1	0	0	0	0	2	1	0	0	0	0	0	5	0	0	0	0	0	0	0
k	1	2	8	4	1	1	2	5	0	0	0	0	5	0	2	0	0	0	6	0	0	0	. 4	0	0	3
1	2	10	1	4	0	4	5	6	13	0	1	0	0	14	2	5	0	11	10	2	0	0	0	0	0	0
m	1	3	7	8	0	2	0	6	0	0	4	4	0	180	0	6	0	0	9	15	13	3	2	2	3	0
n	2	7	6	5	3	0	1	19	1	0	4	35	78	0	0	7	0	28	5	7	0	0	1	2	0	2
0	91	1	1	3	116	0	0	0	25	0	2	0	0	0	0	14	0	2	4	14	39	0	0	0	18	0
p	0	11	1	2	0	6	5	0	2	9	0	2	7	6	15	0	0	1	3	6	0	4	1	0	0	0
q	0	0	1	0	0	0	27	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
r	0	14	0	30	12	2	2	8	2	0	5	8	4	20	1	14	0	0	12	22	4	0	0	1	0	0
S	11	8	27	33	35	4	0	1	0	1	0	27	0	6	1	7	0	14	0	15	0	0	5	3	20	1
t	3	4	9	42	7	5	19	5	0	1	0	14	9	5	5	6	0	11	37	0	0	2	19	0	7	6
u	20	0	0	0	44	0	0	0	64	0	0	0	0	2	43	0	0	4	0	0	0	0	2	0	8	0
v	0	0	7	0	0	3	0	0	0	0	0	1	0	0	1	0	0	0	8	3	0	0	0	0	0	0
w	2	2	1	0	1	0	0	2	0	0	1	0	0	0	0	7	0	6	3	3	1	0	0	0	0	0
х	0	0	0	2	0	0	0	0	0	0	0	0	0	0	0	0	0	0	9	0	0	0	0	0	0	0
У	0	0	2	0	15	0	1	7	15	0	0	0	2	0	6	1	0	7	36	8	5	0	0	1	0	0
z	0	0	0	7	0	0	0	0	0	0	0	7	5	0	0	0	0	2	21	3	0	0	0	0	3	0

#### Kernighan's Confusion Matrix

#### Insertion of Y after X

X											,	Y (It	ıserte	d Le	tter)											
	a	b	c	d	e	f	g	h	i	j	k	1	m	n	O	p	q	r	S	t	u	ν	w	X	У	$\mathbf{z}$
a	15	1	14	7	10	0	1	1	33	1	4	31	2	39	12	4	3	28	134	7	28	0	1	1	4	1
b	3	11	0	0	7	0	1	0	50	0	0	15	0	1	1	0	0	5	16	0	0	3	0	0	0	0
c	19	0	54	1	13	0	0	18	50	0	3	1	1	1	7	1	0	7	25	7	8	4	0	1	0	0
. d	18	0	3	17	14	2	0	0	9	0	0	6	1	9	13	0	0	6	119	0	0	0	0	0	5	0
е	39	2	8	76	147	2	0	. 1	4	0	3	4	6	27	5	1	0	83		6	4	1	10	2	8	0
f	1	0	0	0	2	27	1	0	12	0	0	10	0	0	0	0	0	5	23	0	1	0	0	0	1	0
g	8	0	0	0	5	1	5	12	8	0	0	2	0	1	1	0	1	5	69	2	3	0	1	0	0	0
h	4	1	0	1	24	0	10	18	17	2	0	1	0	1	4	0	0	16	24	22	1	0	5	0	3	0
i	10	3	13	13	25	0	1	1	69	2	1	17	11	33	27	1	0	9	30	29	11	0	0	1	0	1
j	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0
k	2	4	0	1	9	0	0	1	1	0	1	1	0	0	2	1	0	0	95	0	1	0	0	0	4	0
1	3	1	0	1	38	0	0	0	79	0	2	128	1	0	7	0	0	0	97	7	3	1	0	0	2	0
m	11	1	1	0	17	0	0	1	6	0	1	0	102	44	7	2	0	0	47	1	2	0	1	0	0	0
n	15	5	7	13	52	4	17	0	34	0	1	1	26	99	12	0	0	2	156	53	1	1	0	0	1	0
0	14	1	1	3	7	2	1	0	28	1	0	6	3	13	64	30	0	16	59	4	19	1	0	0	1	1
p	23	0	1	I	10	0	0	20	3	0	0	2	0	0	26	70	0	29	52	9	1	l	1	0	0	0
q	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0
r	15	2	1 ~	0	89	1	1	2	64	0	0	5	9	7	10	0	0	132	273	29	7	0	1	0	10	0
S	13	1	7	20	41	0	1	50	101	0	2	2	10	7	3	1	0	1	205	49	7	0	1	0	7	0
	39	0	0	3	65	1	10	24	59	1	0	6	3	1	23	1	0		264	183	11	0	5	0	6	0
u	15	0	3	0	9	0	0	1	24	1	I	3	3	9	1	3	0	49	19	27	26	0	0	2	3	0
v	0	2	0	0	36	0	0	0	10	0	0	1	0	1	0	1	0	0	0	0	1	5	1	0	0	0
w	0	0	0	1	10	0	0	Ţ	1	0	1	1	0	2	0	0	1	1	8	0	2	0	4	0	0	0
X	0	0	18	0	1	0	0	6	1	0	0	0	Ţ	0	3	0	0	0	2	0	0	0	0	1	0	0
У	5	1	2	0	3	0	0	0	2	0	0	1	1	6	0	0	0	1	33	1	13	0	1	0	2	0
2	2	0	0	0	5	1	0	0	6	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	2	4
@	46	8	9	8	26	11	14	3	5	1	17	5	6	2	2	10	0	6	23	2	11	1	2	1	l	2

## Wikipedia

https://en.wikipedia.org/wiki/Wikipedia:Lists\_of\_common\_misspellings/C

- •carmel (caramel, Carmel-by-the-Sea)
- •carniverous (carnivorous)
- •carraige (carriage)
- •carrear (career)
- •carred (cared, carried)
- •carreer (career)
- •carrer (career)
- <u>Carribbean</u> (Caribbean)
- <u>Carribean</u> (Caribbean)

- <u>carring</u> (caring, carrying)
- •carryng (carrying)
- <u>Carthagian</u> (Carthaginian)
- •<u>carthographer</u> (cartographer)
- •cartilege (cartilage)
- •cartilidge (cartilage)
- •<u>cartrige</u> (cartridge)
- •casette (cassette)
- •casion (caisson)
- <u>cassawory</u> (cassowary)

#### Peter Norvig's Single-Edit Corrections List

https://norvig.com/ngrams/count\_ledit.txt

e i	917	er re	189	B b	9
ale	856	i is	133	AIE	9
i e	771	ulo	130	-	9
ela	749	h he	129	ylya	8
ali	559	s se	128	x s	8
t te	478	olor	127	w e	8
r re	392	ula	126	wo ow	8
s c	383	yli	125	cr c	6
elea	354	alu	123	agla	6
alo	353	is i	122	I I†	6
ola	352	ei ie	122	<b>&gt;p &gt;</b>	6
alal	352	al a	122	le	6
i a	313	el le	121	z x	5
re r	299	s st	120	z c	5
elo	295	u ur	119	y †	5
				yl ly	5

### Smoothing

Bagaimana jika ada **unseen errors**? Bisa menghasilkan nilai probabilitas O. Ini tidak kita harapkan karena terlalu berlebihan.

**Contoh:** di Kernighan's substitution confusion matrix, substitusi dari **q** ke **a** dan **a** ke **q** bernilai O. Padahal huruf **q** dan **a** bertetangga di keyboard.

$$\hat{P}(w) = \frac{C(w) + 0.5}{T} \qquad \hat{P}(x|w) = \frac{sub[w_i, x_i] + 1}{count[w_i] + |A|}$$

Banyaknya alphabet

#### acress?

Candidate Correction	Correct Letter	Error Letter	x/w	P(x w)	P(w)	10° *P(x w)P( w)
actress	t	_	c c t	.000117	.0000231	2.7
cress	-	a	a #	.00000144	.000000544	.00078
caress	ca	ac	ac  ca	.00000164	.00000170	.0028
access	С	r	r c	.000000209	.0000916	.019
across	0	е	e o	.0000093	.000299	2.8
acres	-	s	es  e	.0000321	.0000318	1.0
acres	_	s	ss	.0000342	.0000318	<b>1.0</b> <sup>43</sup>

Gambar diambil tanpa malu dari slide Chris Manning & Pandu Nayak, IR & Web Search, Stanford U.